贪心算法

东南大学计算机学院 方效林



本章内容

- 贪心算法要素
- 活动选择问题
- 哈夫曼编码问题
- 最小生成树问题
- 单源最短路径问题

贪心算法要素

- 贪心算法的基本思想
 - □求解最优化问题的算法包含一系列步骤
 - □每一步都有一组选择
 - □ 作出在当前看来最好的选择
 - □ 希望通过作出局部最优选择达到全局最优选择
 - 。贪心算法不一定总产生最优解
 - □ 贪心算法是否产生优化解. 需严格证明
- 贪心算法产生最优解的条件
 - 。最优子结构
 - □ 贪心选择性

贪心算法要素

■ 最优子结构

当一个问题的最优解包含子问题的最优解时,称这个问题具有最优子结构

■ 贪心选择性

- 当一个问题的全局最优解可以通过局部最优解得到, 称这个问题具有贪心选择性
- □ 证明思路:
 - ▶假定首选元素不是贪心选择所要的元素,证明将首元素替换成贪心选择所需元素,依然得到最优解
 - 数学归纳法证明每一步均可通过贪心选择得到最优解



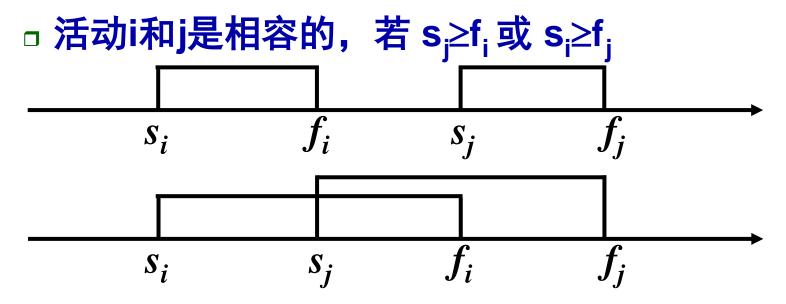
贪心算法要素

- 动态规划方法可用的条件
 - 。最优子结构
 - □ 子问题重叠性
- 贪心算法产生最优解的条件
 - 。最优子结构
 - □ 贪心选择性
- 适用贪心算法时,动态规划可能不适用
- 适用动态规划时,贪心算法可能不适用

活动

S={1,2,...,n}是n个活动的集合,活动共用同一资源,同一时间只有一个活动使用。活动 i有起始时间 s_i,终止时间 f_i, s_i≤ f_i,表示为x_i=[s_i, f_i]

■ 相容活动



■ 问题定义

□ 输入: S={1, 2, ..., n}, x_i=[s_i, f_i], 1 ≤ i ≤ n

□ 输出: S的最大相容集合

贪心思想

□ 为了选择更多活动,每次选择 f; 最小的活动



```
S按结束时间排序,f_1 \le f_2 \le .... \le f_n Greedy-Activity-Selector(S, F) n = length(S); A = \{1\}; j = 1; for i = 2 to n do if s_i \ge f_j then A = A \cup \{i\}; j = i; return A
```

$$T(n) = \theta(n) + \theta(nlogn)$$
$$= \theta(nlogn)$$

■ 最优子结构性质

设活动S={1, 2, ..., n}已按结束时间递增排序,即
 f₁≤f₂≤....≤f_n,设A是包括活动 1 的最优解,则
 A'=A-{1} 是 S'={i∈S|s_i≥f₁}的最优解。

□ 证明:

- ▶ 显然A'中的活动是相容的,只需证A'是最大的。
- ▶ 若不然,假设B'是最大的,且|B'| > |A'|。
- ▶ 那么B={1}∪B'是最优解,但|B| =1+|B'| > 1+|A'|=|A|
- ▶ 这与A是最大的(最优解)矛盾。

问题的最优解包含子问题的最优解

■ 贪心选择性

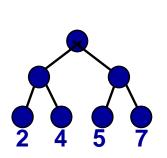
□ 设活动S={1, 2, ..., n}已按结束时间递增排序,即 $f_1 \le f_2 \le \le f_n$ 。每次选结束时间最小的相容活动, 可得最优解A。

□ 证明:

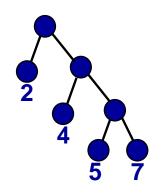
- ▶ 设贪心最优解 A 也按结束时间递增排序,设其第一个活动为 k,第二个活动为 j
- ▶ 若k=1,则成立
- ▶ 若 $k\neq 1$,由于 A 中活动相容,有 $f_k \le s_j$,由于 $f_1 \le f_k$, 因此,可以用活动 1 代替活动 k

■ 带权路径长度

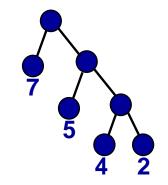
□假设二叉树中每个叶结点有一个权值 w_i ,到根的路径长度为 l_i ,其他结点权值为0,则有n个叶子结点的树的带权路径长度为 $w_{PL} = \sum_{i=1}^{n-1} w_i * l_i$



WPL=2*(2+4+5+7)=36



WPL=2+2*4+3*(5+7)=46

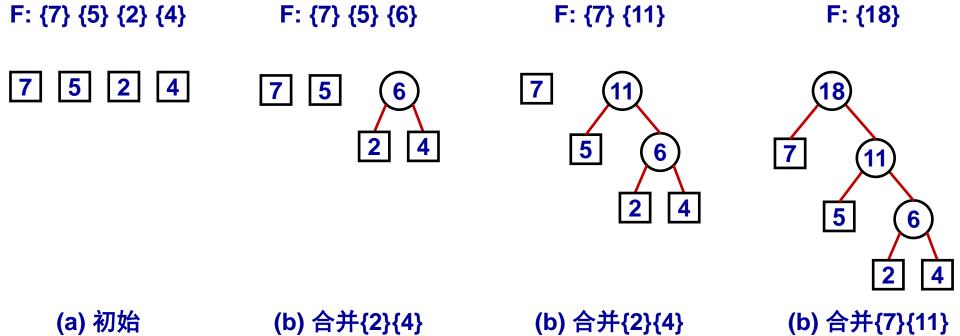


WPL=7+2*5+3*(4+2)=35

带权路径长度达到最小的二叉树即为Huffman树。 在Huffman树中,权值越大的结点离根越近。

- 构造权值为{w₁,w₂, ..., wₙ}的Huffman树
 - □构造n棵二叉树的森林F={T₁,T₂,...,T_n},每棵二叉 树T_i只有一个带权值为w_i的根结点
 - □ 重复以下步骤,直到只剩一棵树为止:
 - ▶ 1. 在F中选两棵根结点权值最小的二叉树,作为左、 右子树构造一棵新的二叉树,新树的根结点权值等于 其左、右子树根结点权值之和
 - ▶ 2. 在F中删除这两棵二叉树
 - > 3. 把新构造的二叉树加入F







- Huffman编码,进行数据压缩
 - □ 计算机领域数据用二进制表示
 - □ 若已统计出某文本中各字符出现的概率,可以用 Huffman编码进行数据压缩

概率 = 某字符出现次数 总字符数

- Huffman编码,进行数据压缩
 - 。假设某文本共有1000个字符, 且只由 a, b, c, d, e 5种字符组成
 - ▶ 固定长度编码可将每个字符用3比特表示,整个文本 要3*1000=3000比特表示,平均编码长度3比特

符号	定长编码
a	000
b	001
c	100
d	101
e	110

- Huffman编码,进行数据压缩
 - □ 假设某文本共有1000个字符, 且只由 a, b, c, d, e 5种字符组成
 - ▶ 若已统计出各字符出现的概率分别为0.12, 0.40, 0.15, 0.08, 0.25, 则整个文本可用2150比特表示

平均编码长度(带权路径长度)

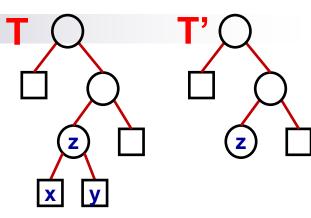
$$B(T) = 0.12*4 + 0.08*4 + 0.15*3 + 0.25*2 + 0.40*1$$

5

1.0			B(T) = 0.1
0			= 2.1
0.40(b)	$\langle 0.6 \rangle$	1	
h 25		<u></u>	
0.25		.35	
	0.15(c)		.2)
	0.13(c)	9	1
	0.0	8(d)	0.12(a)
	9 1 3	- (3-)	_ (32)

符号	概率	Huffman编码
a	0.12	1111
b	0.40	0
c	0.15	110
d	0.08	1110
e	0.25	10





■ 最优子结构

T是字符表C一棵哈夫曼树。设字符x和y是T中任意两个相邻叶结点,z是其父结点,f(x)和f(y)是其频率。将z看作频率是f(z)=f(x)+f(y)的字符,T'=T-{x,y}是字母表C'=C-{x,y}∪{z}的哈夫曼树

□ 证明:

▶ 若T'不是C'的哈夫曼树(最优解),则必存在T",使B(T")<B(T')。因为z是C'中字符,它必为T"中的叶子。把结点x与y加入T",作为z的子结点,得到C的哈夫曼树T", B(T")=B(T")+f(x)+f(y)<B(T')+f(x)+f(y)<B(T)。这与T是C的哈夫曼树矛盾。

问题的最优解包含子问题的最优解

a b x y

■ 贪心选择性

。设C是字符表,字符x和y是C中频率最小的两个字符,则存在一棵哈夫曼树,使得x与y编码长度最长(即到根路径长度最长)

- 证明:

- ▶ 假设一哈夫曼树编码长度最长的不是x和y,是a和b, 且f(a)≥f(x), f(b)≥f(y),则L(a)≥L(x), L(b)≥L(y), L指编 码长度,如左图所示。分别将a和x,b和y交换,得到
- > B(T') = B(T) f(x)L(x) f(y)L(y) f(a)L(a) f(b)L(b)
- +f(x)L(a)+f(y)L(b)+f(a)L(x)+f(b)L(y)
- > =B(T)+(fx-fa)(La-Lx)+(fy-fb)(Lb-Ly) ≤ B(T)
 优先选择频率最小的x和y结果并不会变坏



- 互不相交的集合 (等价类的划分)
 - □ 需要经常合并集合 (等价类的合并)
 - □需要经常查找元素属于哪个集合



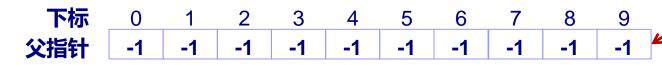
- 并查集支持以下操作
 - □ 初始化UFSets(s): 将s中每个元素自成一个集合
 - □ 合并Union(Root1,Root2): 集合Root2并入Root1
 - □ 查找Find(x): 查找元素x属于哪个集合



- 用树表示集合
 - □ 初始化时,每个元素自成为一棵树
 - 0 1 2 3 4 5 6 7 8 9

全集合S初始化时形成的森林

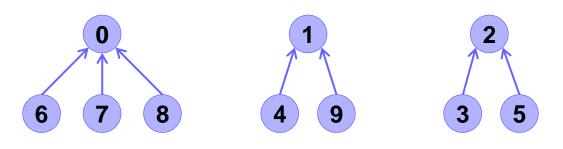
负数表示没有父结点 -1表示树中有1个结点 -2表示有2个结点, 以此类推



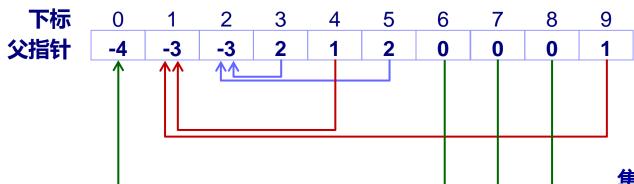
初始化时形成的父指针表示

■ 用树表示集合

假设经过若干合并后有3个集合{0,6,7,8}, {1,4,9}{2,3,5}

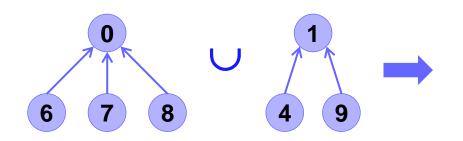


集合的树形表示

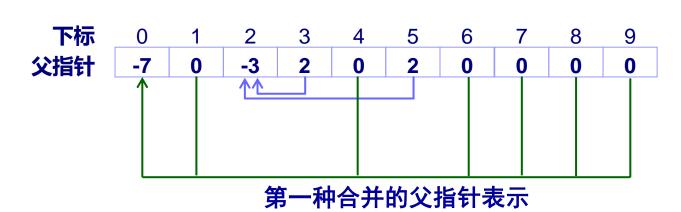


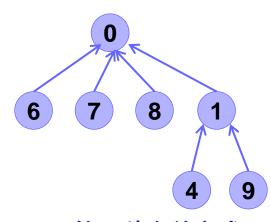
■ 用树表示集合

- □ 合并 s_1 ={0,6,7,8} \cup s_2 ={1,4,9}
 - ▶ s₂作为s₁根的子树,或相反

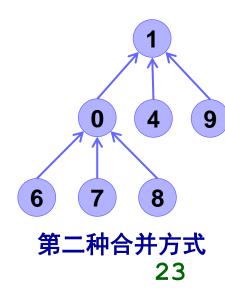


合并集合





第一种合并方式



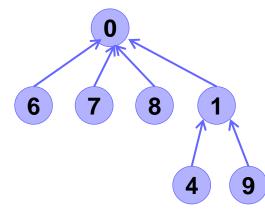
■ 用树表示集合

- \Box 合并 $s_1 = \{0,6,7,8\} \cup s_2 = \{1,4,9\}$
 - ▶ s₂作为s₁根的子树,或相反
 - ▶ 哪一种合并方式好?
 - > 先介绍查找Find操作
 - □ Find(4)表示4所属集合,返回值0号结点(即根结点)
 - □ Find操作时间相当于结点到根路径长度

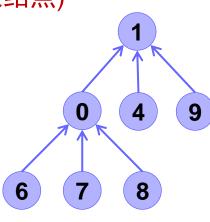


合并方式:

将结点数更少的集合作为结点数更多的集合的根的子树



第一种合并方式



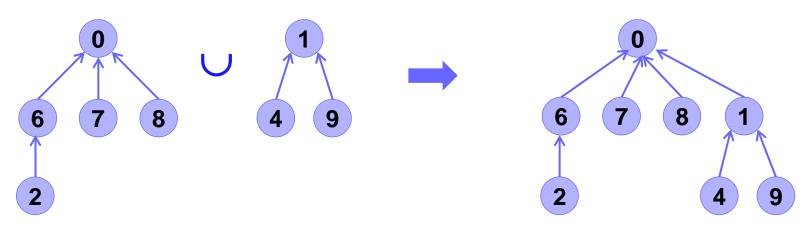
第二种合并方式

×

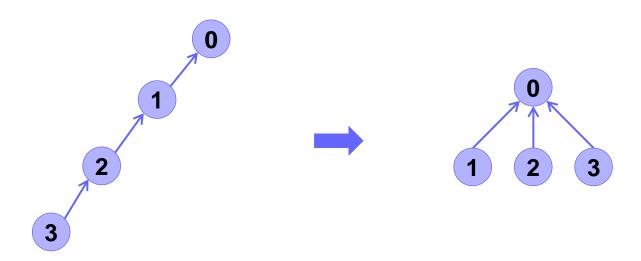
并查集

■ 用树表示集合

- □ 合并 s_1 ={0,2,6,7,8} \cup s_2 ={1,4,9}
 - > 令秩表示树的深度
 - > 将秩更小的树作为秩更大的树的根的子树



- 用树表示集合
 - □ 路径压缩,在find过程中顺便压缩



按秩合并与路径压缩方式, 操作的平均代价为 $O(\alpha(n))$

 $\alpha(n)$ 是n = f(x) = A(x,x)的反函数 其中A是急速增加的阿克曼函数 $\alpha(n)$ 在n十分巨大时还是小于5

w

最小生成树

■ 生成树

设G=(V, E)是一个边加权无向连通图。G的生成树是无向树S=(V, T), T⊆E。W是G的权函数, T权值定义为W(T)=∑_{(u,v)∈T}W(u,v)</sub>

■ 最小生成树

□ G的最小生成树是W(T)最小的G的生成树

■ 问题的定义

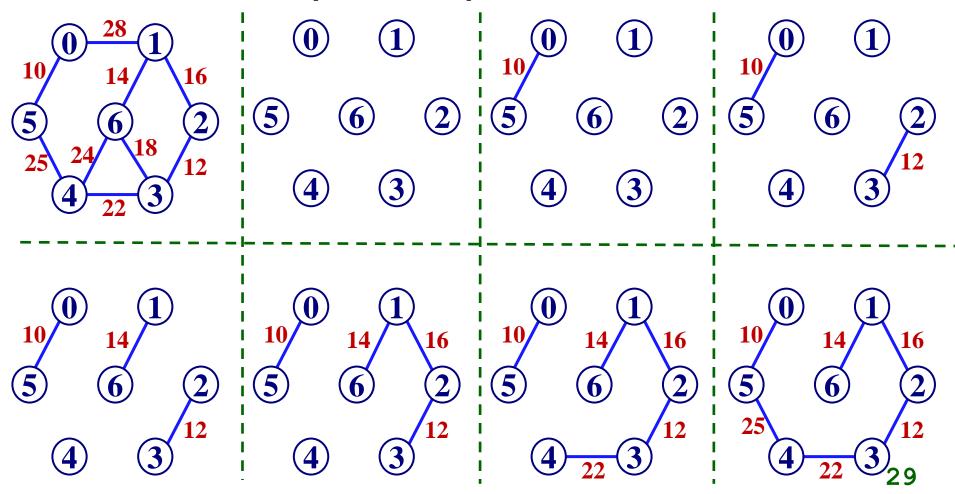
□ 输入: 无向连通图G=(V, E), 权函数W

□ 输出: G的最小生成树

м

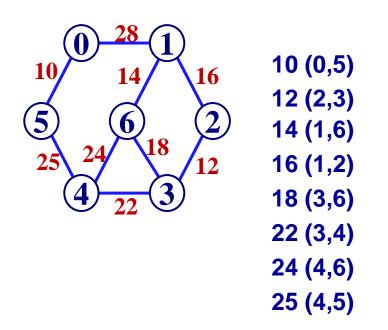
- 克鲁斯卡尔 (Kruskal) 算法
 - □ 初始时所有顶点自成一集合
 - □ 在图上选权值最小的边e_{min},判断e_{min}两端点是否 属于不同集合c_i,c_i
 - ▶ 若是,将c_i,c_i用e_{min}连接成同一个集合
 - ▶ 否则,舍弃e_{min}
 - □ 重复上一过程,直到所有顶点在同一集合

■ 克鲁斯卡尔 (Kruskal) 算法





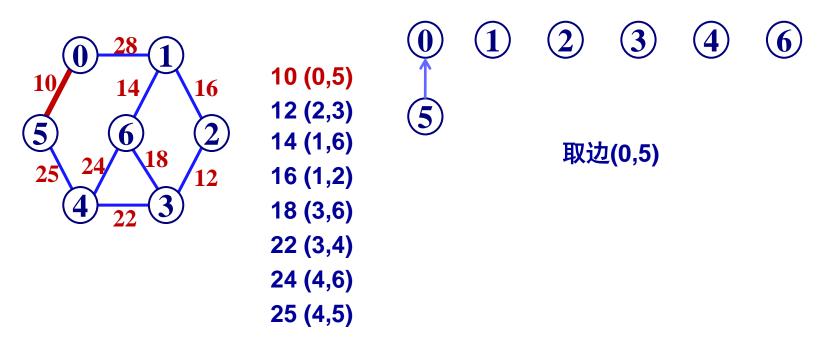
- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - 可使用并查集技术加快判断速度





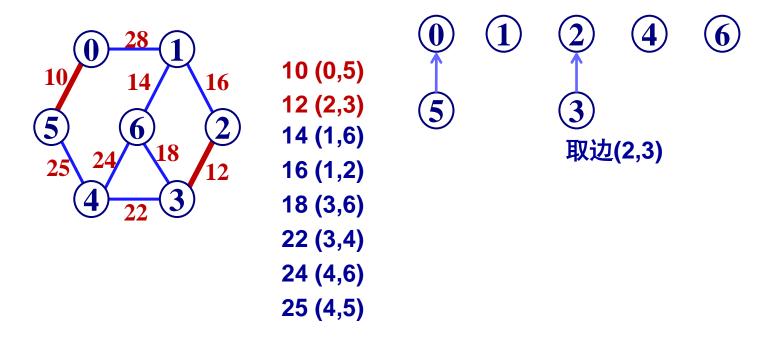


- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - 可使用并查集技术加快判断速度

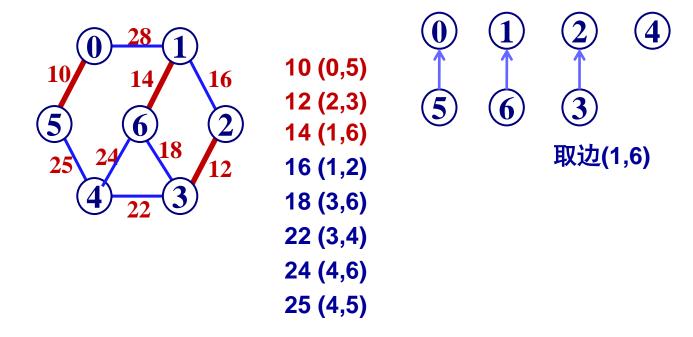




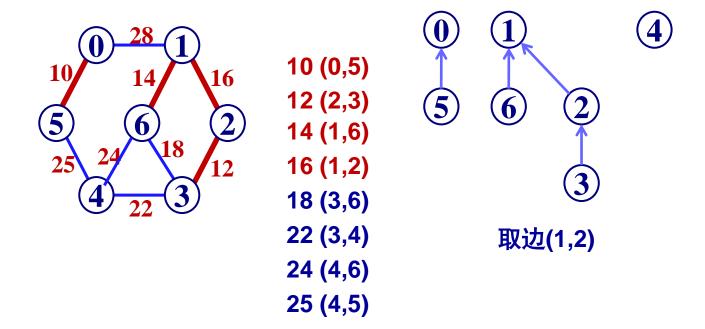
- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - 可使用并查集技术加快判断速度



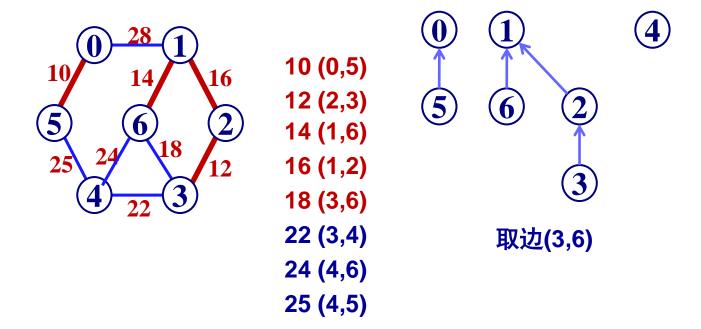
- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - 可使用并查集技术加快判断速度



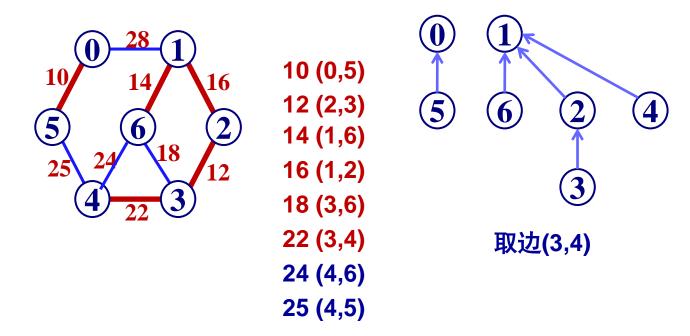
- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - 可使用并查集技术加快判断速度



- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - > 可使用并查集技术加快判断速度

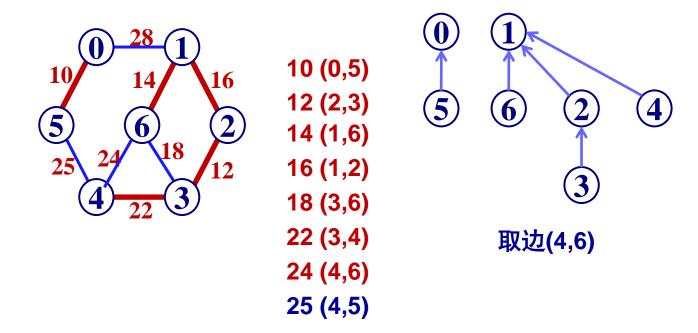


- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - 可使用并查集技术加快判断速度



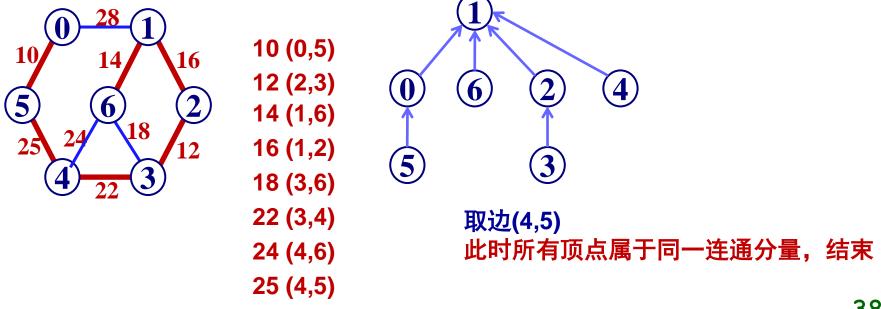
最小生成树

- 克鲁斯卡尔 (Kruskal) 算法
 - 经常需要判断权值最小的边的两端是否属于不同连通分量
 - 可使用并查集技术加快判断速度

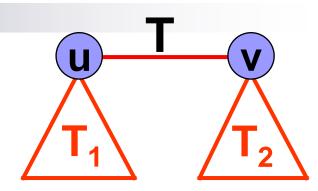


最小生成树

- 克鲁斯卡尔 (Kruskal) 算法
 - □ 经常需要判断权值最小的边的两端是否属于不同连 通分量
 - > 可使用并查集技术加快判断速度







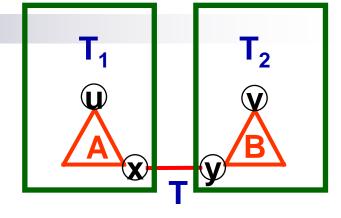
■ 最优子结构

。设T是 G的最小生成树。不妨设T 包含子树 T_1 和 T_2 , T_1 是G的子连通图 G_1 的生成树, T_2 是G的子连通图 G_2 的生成树,则 T_1 是 G_1 的最小生成树, T_2 是 G_2 的最小生成树

- 证明:

》若T₁和T₂不是G₁和G₂的最小生成树,而最小生成树分别是T'₁和T'₂,即W(T'₁) ≤ W(T₁),W(T'₂) ≤ W(T₂),则存在最小生成树W(T')=W(T'₁)+W(T'₂)+W(u,v)≤ W(T₁)+W(T₂)+W(u,v) W(T),与T是最小生成树矛盾。

最小生成树



■ 贪心选择性

设边(u,v)是当前权值最小且两端点分别属于不同两个集合A和B的边,则必然存在一棵最小生成生树包含边(u,v)。

□ 证明:

▶ 如图所示,假设不存在一棵最小生成树包含边(u,v)。 为了得到生成树,A和B之间必然有一条路径连接。假设这条路径连接A和B包含边(x,y) 得到最小生成树T。 W(u,v)≤W(x,y),边(x,y)可将T划分两棵子树 T_1 和 T_2 。 不妨设A \subseteq T₁,B \subseteq T₂,W(T')=W(T₁)+W(T₂)+W(u,v)≤ W(T₁)+W(T₂)+W(x,y)=W(T),与T最小矛盾。得证。

选择当前权值最小且两端点属两集合结果并不会变坏

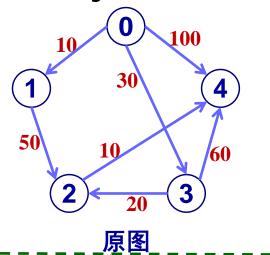


- 单源最短路径的Dijkstra算法
 - □ 给定带权图 (每条边权值≥0)
 - □ 给定源点v,求v到其他顶点的最短路径

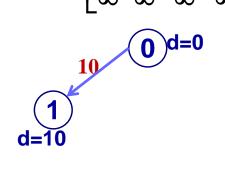
■ Dijkstra算法

- □ 初始时令S={v₀}, dist[v₀]=0, dist[i]=Edge[v₀][i]
- 找u∈S,v∉S,且dist[u]+Edge[u][v]最小,则将v加入S中,dist[v]=dist[u]+Edge[u][v]
- □ 重复上一步骤,直到所有顶点都加入S中

■ Dijkstra算法(不记录路径)





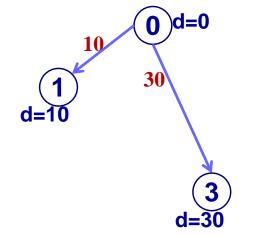


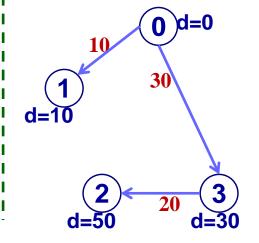
Edge =

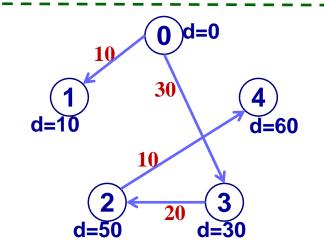
 $10 \infty 30 100$

10

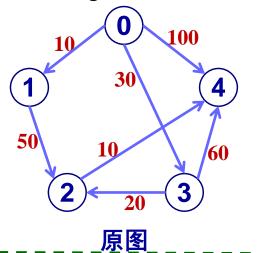
60



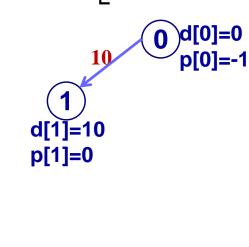




■ Dijkstra算法(记录路径)







 ∞

Edge =

 $10 \, \infty \, 30 \, 100$

 ∞

 ∞

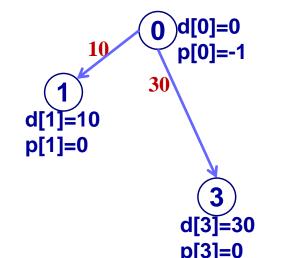
10

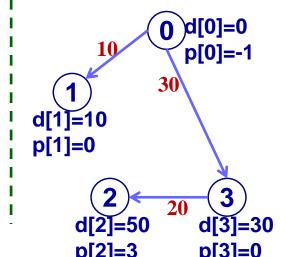
60

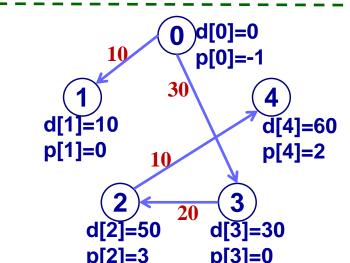
0

50

 ∞







M

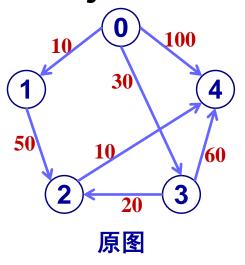
最短路径

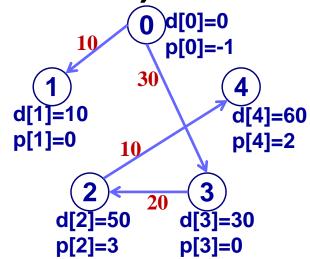
 $10 \infty 30 100$

10

60

■ Dijkstra算法(记录路径)





获取最短路径方法,以顶点4为例:

$$p[4]=3 \Rightarrow p[3]=2 \Rightarrow p[2]=0$$

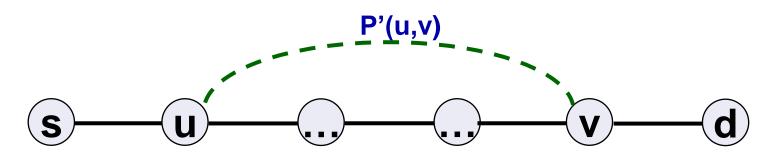
反向读得0到4的最短路径为 (0,3,2,4)

■ 最优子结构

□ 设P(s,d)是s到d的最短路径,那么这条路径上的子路径P(u,v)是u到v的最短路径。

□ 证明:

▶ 如若不然,假设u到v之间存在更短路径P'(u,v),则用 其替代P(u,v),得到一条s到d的更短路径P'(s,d),与 P(s,d)是s到d是最短路径矛盾。

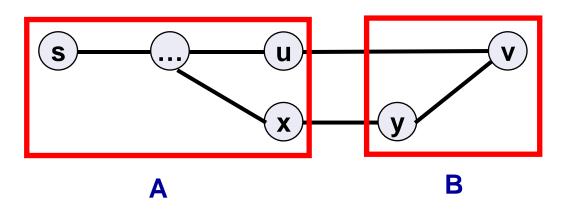


■ 贪心选择性

□设A是已计算好最短路径的顶点集合,B是未计算好最短路径的顶点集合。P是s到u的最短路径。假设W(P)+W(u,v)对任意u∈A, v∈B最小,则P+{(u,v)}是s到v的最短路径

- 证明:

> 略

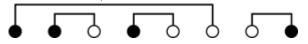


选择当前累积权值最小且两端点属两集合结果不会变坏

POJ 2393 1328

- (1) 给定n个物品,物品价值分别为 P_1 , P_2 , ..., Pn, 物品重量分别 W_1 , W_2 , ..., Wn, 背包容量为M。每种物品可部分装入到背包中。输出 X_1 , X_2 , ..., X_n , $0 \le X \le 1$, 使得 $\sum_{1 \le i \le n} P_i X_i$ 最大,且 $\sum_{1 \le i \le n} W_i X_i \le M$ 。试设计一个算法求解该问题,分析算法的正确性。
- (2)海面上有一些船需要与陆地进行通信,需要在海岸线上布置一些基站。现将问题抽象为,在x轴上方,给出N条船的坐标 $p_1, p_2, ..., p_N$, $p_i = (x_i, y_i)$, $x_i \geq 0, y_i \leq d, 1 \leq i \leq N$,在x轴上安放的基站可以覆盖半径为d的区域内的所有点,问在x轴上至少要安放几个点才可以将x轴上方的点都覆盖起来。试设计一个算法求解该问题,并分析算法的正确性。 $\uparrow p_2$

- 某公司有个工厂和仓库。由于原材料等价格波动,工厂每个月的生产成本也会波动,令第i个月产品的单位生产成本为 c_i (该月生产一个产品的成本为 c_i)。仓库储存产品的也有成本,假设每个月产品的单位储存成本为固定值1(存储一个产品一个月的成本为1)。令第i个月需要供应给客户的产品数量为 y_i ,仓库里的和生产的产品均可供应给客户。假设仓库的容量无限大,供应给客户剩余的产品可储存在仓库中。若已知n个月中各月的单位生产成本 c_i 、以及产品供应量 y_i ,设计一算法决策每个月的产品生产数量 x_i ,使得n个月的总成本最低。例如:n=3, c_i : 2,5,3, y_i : 2,4,5,则 x_i : 6,0,5,即第1个月生产6个供应2个(代价2×2=4),储存4个供应给第2个月(代价(2+1)×4=12),第3个月生产5个供应5个(代价3×5=15),使总成本4+12+15=31最小。
- 给定直线上 2n个点的序列P[1,2,...,2n],每个点 P[i]要么是白点要么是黑点,其中共有n个白点和 n个黑点,相邻两个点之间距离均为1,请设计一个算法将每个白点与一黑点相连,使得连线的总长度最小。例如,图中有4个白点和4个黑点,以图中方式相连,连线总长度为1+1+1+5=8。





■ 有n个作业需要在一台机器上执行,一个时刻机器上只能执行一个作业,每个作业可在单位时间内完成,作业i有截止时间di,当作业i在截止时间被执行完,则可获得pi的收益,请设计算法获得最大收益,并分析算法的正确性。

 假设有数目不限的面值为25美分,10美分,5 美分,1美分的硬币,请使用最少个数的硬币 凑出3.33美元。